

OfferExp

Plataforma de Experimentação Adaptativa para Ofertas Financeiras

Multi-Armed Bandits · Thompson Sampling · Azure

Grupo 77 · Geremias Francisco · Wagner Ulisses Fontalva
Pós-Tech FIAP 7MLET · Junho 2026

O Problema

Instituições financeiras precisam decidir, **em tempo real e em escala**, qual oferta apresentar a cada cliente nos canais digitais.

Abordagem	Limitação
Regras fixas	Não se adapta à mudança de comportamento
Testes A/B	Desperdiça tráfego em braços sabidamente ruins
ML supervisionado	Requer retraining offline periódico; não aprende em tempo real

Custo real: em um A/B test de 90 dias com 4 variantes, 75% do tráfego é alocado a braços sub-ótimos durante toda a duração do experimento.

Nossa Solução: OfferExp

Uma plataforma de experimentação adaptativa que aprende continuamente qual oferta maximiza conversão — sem regras fixas, sem testes A/B tradicionais.

```
Cliente → POST /decide → Thompson Sampling → Oferta apresentada
                                     ↓
                             (dias depois) POST /reward → Modelo atualizado
```

4 braços de oferta:


- `sem_oferta` — grupo controle
- `educacao_financeira` — conteúdo educativo
- `simulador_credito` — ferramenta interativa
- `cartao_premium` — produto financeiro

Thompson Sampling: Como Funciona

Cada braço tem uma distribuição de probabilidade de conversão — **Beta(α , β)** — que é atualizada a cada observação.

Regra de decisão: sorteia um valor de cada distribuição → escolhe o maior.

- Braços com **alta incerteza** (poucos dados) têm distribuições largas → alta chance de serem escolhidos para exploração
- Braços com **muitos dados** e boa taxa → distribuições estreitas em torno do valor real → exploração natural



Demonstração ao Vivo

API rodando localmente · 3 chamadas · 60 segundos

Demonstração

1. Iniciar API

```
make serve          # FastAPI em localhost:8000
```

2. Solicitar decisão

```
curl -s -X POST localhost:8000/decide \  
  -H "Content-Type: application/json" \  
  -d '{"event_id": "demo-01", "context": {"profissao": "admin"}}'
```

```
{ "arm_name": "cartao_premium", "reason_codes": ["thompson_sample_arm_3"],  
  "policy_version": "thompson-v1" }
```

3. Registrar reward

```
curl -s -X POST localhost:8000/reward \  
  -d '{"event_id": "demo-01", "arm_id": 3, "reward": 1}'
```

4. Verificar atualização

```
curl -s localhost:8000/stats | python3 -m json.tool
```


Evidências Quantitativas

Método: Replayer Offline (Li et al., 2011) — estimativa imparcial usando apenas eventos com braço matching.

Política	Reward médio	Regret (5k rounds)	% melhor braço
Random (baseline)	~11,0%	Alto — linear	~25%
Greedy	~11,2%	Médio	~60%
Thompson Sampling	~11,8%	Sublinear	~70%

Estabilidade: 5 sementes aleatórias (0, 7, 42, 123, 999) → $CV < 2\%$
(registrado no MLflow — Notebook 06)

Regret Acumulado



Thompson Sampling cresce sublinearmente — a lacuna em relação ao oráculo diminui com o tempo.

Arquitetura Azure

Camada	Serviço	Decisão
API / Gateway	API Management	Rate limiting, OAuth2
Compute	Container Apps	Zero-downtime, autoscale
Estado bandit	Cosmos DB	Latência < 10ms para α , β
Logs auditáveis	Blob Storage (WORM)	Imutável, 5 anos
Delayed rewards	Service Bus	Exactly-once delivery
MLOps	Azure ML + MLflow	Tracking, model registry
IA / Explicabilidade	Azure OpenAI GPT-4o	Assistente em PT
Segredos	Key Vault + Managed Identity	Zero credenciais hardcoded

Custo estimado (dev/staging): ~US\$ 76/mês

Riscos e Governança

4 cenários de risco documentados e mitigados:

Risco	Mitigação
Reward hacking	Validação [0,1] + alerta >50% reward=1 em 1h
Manipulação de contexto	Pydantic whitelist + validação de ranges
Abuso do assistente LLM	System prompt restritivo + logs auditáveis
Violação de suitability	Guardrails: idade < 18 → sem_oferta ; inadimplência → sem cartao_premium

Conformidade LGPD:

- `subject_key` = hash SHA-256 — nenhum dado direto identificável
- Dados sensíveis (art. 5, II): **não coletados**
- Retenção: logs 5 anos · API logs 90 dias · Notificação ANPD ≤ 72h

Impacto e Próximos Passos

O que entregamos:

- ✓ Plataforma end-to-end: dados → API → MLOps → Azure → Governança
- ✓ 112 testes automatizados (`make test`) com evidências por etapa
- ✓ Thompson Sampling convergindo 7% acima do Random, regret sublinear
- ✓ Model card · System card · LGPD · Arquitetura-alvo documentados

O que vem a seguir:

1. **Thompson Contextual (LinThompson)** — incorporar features do cliente na seleção
2. **Fairness constraints** — taxa mínima de exposição por segmento demográfico
3. **Feedback loop completo** — retreino automático com dados reais via Azure ML Pipeline
4. **Dashboard em tempo real** — distribuições Beta por braço em Power BI / Grafana

Obrigado

Geremias Francisco · geremias_cte@hotmail.com

Wagner Ulisses · wagner.ulisses@gmail.com

 → 112 testes passando

 → API rodando em localhost:8000

 → toda a documentação versionada no repositório

Perguntas?