

OfferExp

Plataforma de Experimentação Adaptativa para Ofertas Financeiras

Multi-Armed Bandits · Thompson Sampling · Azure

Grupo 77 · Geremias Francisco · Wagner Ulisses Fontalva

Pós-Tech FIAP · Datathon 7MLET

Problema e Solução

Uma instituição financeira digital precisa decidir qual oferta apresentar a cada cliente.
Regras fixas não se adaptam. Testes A/B desperdiçam tráfego em braços sabidamente ruins.

Nossa solução — OfferExp: API de decisão em tempo real com Multi-Armed Bandit.

```
Cliente → POST /decide → Thompson Sampling → Oferta apresentada
                                   ↓
                             (dias depois) POST /reward → Modelo atualizado automaticamente
```

4 braços de oferta: sem_oferta · educacao_financeira · simulador_credito · cartao_premium

Base: Bank Marketing Dataset (Kaggle · CC0) com camada sintética de eventos, recompensas e delayed rewards.

Dados: Bank Marketing Dataset

Fonte: Kaggle · CC0 · 41.188 clientes de um banco português (2008–2010) · 0% de nulos

Decisão crítica — remoção de `duration` :

A duração da ligação só é conhecida **depois** que o contato acontece. Usá-la como feature seria *data leakage*: o modelo aprenderia com uma informação que não existe no momento da decisão.

```
Kaggle (raw) → limpeza + tradução de colunas → remoção de duration
               → enriquecimento sintético (eventos, braços, rewards)
               → notebooks (EDA → Baseline → Thompson → Avaliação)
```

Camada sintética por cima da base real: taxas de conversão por braço, delayed rewards e eventos de oferta — a base demográfica é real, o mecanismo de oferta é simulado (decisão consciente para um projeto acadêmico, ver `docs/lgpd-plan.md`).

Modelo: Thompson Sampling

Cada braço tem uma distribuição **Beta(α , β)** que representa a incerteza sobre sua taxa de conversão.

Regra de decisão: sorteia um valor de cada distribuição → escolhe o maior.

- Alta incerteza → distribuição larga → maior chance de **exploração**
- Muitos dados e boa taxa → distribuição estreita → **exploração** natural

Política	Reward médio	Regret	% melhor braço
Random (baseline)	~11,0%	Linear	~25%
Greedy	~11,2%	Médio	~60%
Thompson Sampling	~11,8%	Sublinear	~70%

+7% vs Random · estável em 5 sementes (CV < 2%) · rastreado no MLflow

Resultados e Guardrails de Suitability

Avaliação offline pelo Replayer Method (Li et al., 2011) — conta reward só quando a política teria escolhido o mesmo braço do histórico.

3 guardrails automáticos, logados e auditáveis:

Guardrail	Regra	Objetivo
Idade	Cliente < 18 anos → sempre sem_oferta	Proteção de menores
Inadimplência	Cliente em default → nunca cartao_premium	Suitability financeira
Fadiga de contato	faixa_contatos ≥ 20 → sempre sem_oferta	Evita spam ao cliente

Fairness monitorada: Δ na taxa de seleção por braço entre faixas etárias/profissão deve ficar < 10 p.p. — braços não são definidos por atributos protegidos.

Demonstração — API ao Vivo

`make api` → FastAPI em `localhost:8000`

1. Solicitar decisão

```
curl -s -X POST localhost:8000/decide \  
  -H "Content-Type: application/json" \  
  -d '{"event_id": "demo-01", "subject_key": "cliente-42",  
      "context": {"profissao": "admin", "idade": 35}}'
```

```
{ "arm_name": "cartao_premium", "reason_codes": ["thompson_sample_arm_3"],  
  "policy_version": "thompson-v1", "decided_at": "2026-07-15T..." }
```


2. Registrar conversão (reward atrasado)

```
curl -s -X POST localhost:8000/reward \  
  -d '{"event_id": "demo-01", "arm_id": 3, "reward": 1}'
```

3. Consultar estado do modelo

```
curl -s localhost:8000/stats  
# → Alpha/Beta atualizados por braço em tempo real
```

Arquitetura — Microsoft Azure



Por que só Azure: residência de dados dentro do compliance financeiro (BACEN/CVM), **Managed Identity** única cobrindo todos os serviços — nenhuma credencial em texto claro no código.

Deploy: GitHub Actions (pytest + lint + type-check) → build → Container Apps, rollout canary 10% → 50% → 100%, com rollback automático em 1 comando. Custo estimado de dev: **~\$61/mês**.

Governança, Riscos e Próximos Passos

Principais riscos mapeados e mitigados:

- *Reward hacking* → validação de range [0,1] + alerta de anomalia (>50% reward=1/hora)
- *Drift de comportamento* → monitoramento contínuo + reset periódico de prior
- *Explicabilidade* → `reason_codes` em toda decisão; hoje regra determinística

LGPD: só dados sintéticos/públicos hoje. `subject_key` sempre pseudoanonimizado (hash SHA-256); nenhum dado sensível (raça, saúde, religião) é coletado — plano completo em `docs/lgpd-plan.md`.

Roadmap:

1. **LinUCB contextual** — usar o `context` que a API já recebe (idade, profissão) para personalizar por cliente
2. **Assistente LLM (Azure OpenAI + RAG)** — explicar decisões em linguagem natural para analistas e clientes
3. **Human-in-the-loop** — checklist de promoção de política já definido em `docs/mlops-lifecycle.md`

Obrigado

Geremias Francisco · geremias_cte@hotmail.com

Wagner Ulisses · wagner.ulisses@gmail.com

 → pipeline ponta a ponta

 → suíte de testes automatizados

 → model card · system card · LGPD · arquitetura Azure

Repositório: [datathon-7mlet-grupo-77](#)